# Reporte Técnico SIID: Análisis de Riesgos en Supply Chain

**Optimización de Entregas y Modelado Predictivo con DataCo Smart Supply Chain**

Gonzalo Cayunao — Doctorado UNAB

2026-04-15

## Table of contents


**1 Resumen Ejecutivo** **2**

**2 Introducción y Contexto** **2**
- 2.1 Descripción del Dataset . . . 2
- 2.2 Objetivos del Proyecto . . . 2
- 2.3 Calidad de Datos . . . 3
- 2.4 Estadísticas Descriptivas . . . 3

**3 Análisis Exploratorio de Datos (EDA)** **3**
- 3.1 Análisis Temporal . . . 3
- 3.2 Distribución Geográfica y Mercados . . . 4
- 3.3 Distribución del Estado de Entregas . . . 5
- 3.4 Distribuciones de Variables Clave . . . 6
  - 3.4.1 Tiempo Real de Envío . . . 6
  - 3.4.2 Beneficio por Orden . . . 6
- 3.5 Análisis Probabilístico y Teorema de Bayes . . . 7
  - 3.5.1 Probabilidades Marginales y Conjuntas . . . 7
  - 3.5.2 Probabilidades Condicionales vía Bayes . . . 8
- 3.6 Muestreo Aleatorio e Intervalo de Confianza . . . 8
- 3.7 Matriz de Correlación . . . 10

**4 Definición del Problema y Metodología** **11**
- 4.1 Selección del Problema: Late Delivery Risk . . . 11
- 4.2 Preprocesamiento y Prevención de Data Leakage . . . 11

**5 Implementación y Evaluación de Modelos** **11**
- 5.1 Modelo de Regresión: Predicción de Ventas . . . 11
- 5.2 Modelo de Clasificación: Riesgo de Entrega Tardía . . . 13
  - 5.2.1 Paso 1 — Selección de Features por Importancia . . . 13
  - 5.2.2 Paso 2 — Benchmarking de Clasificadores . . . 14
  - 5.2.3 Paso 3 — Métricas por Modelo y Curva ROC . . . 16
- 5.3 Importancia de Variables . . . 17

**6 Conclusiones y Recomendaciones** **18**
6.1 Hallazgos Principales . . . . . 18
6.2 Recomendaciones . . . . . 19

**7 Bibliografía y Referencias** **19**

# 1 Resumen Ejecutivo

Este informe técnico documenta la transformación de datos crudos en inteligencia operativa para la gestión de suministros. Utilizando técnicas avanzadas de **Ciencia de Datos**, hemos analizado el ecosistema de **DataCo Global** para diagnosticar ineficiencias logísticas.

Los resultados demuestran que, a través de modelos predictivos basados en **Gradient Boosting**, es posible anticipar interrupciones en la entrega con una precisión superior al **95%**. El análisis se estructura en cuatro pilares: contextualización del negocio y calidad de datos, diagnóstico exploratorio con análisis probabilístico, benchmarking de modelos predictivos y recomendaciones de optimización estratégica.

# 2 Introducción y Contexto

## 2.1 Descripción del Dataset

El dataset **DataCo Smart Supply Chain** es una base de datos exhaustiva que integra registros de ventas y logística de una empresa con operaciones globales. Consta de **180,519 registros** y **53 variables**, abarcando el periodo 2015–2018.

Las variables principales se agrupan en tres dimensiones:

- **Información del Cliente**: Ubicación geográfica, segmentación y actividad.
- **Logística**: Modos de envío, tiempos reales vs. programados y estado de entrega.
- **Finanzas**: Ventas totales, beneficios por orden y descuentos aplicados.

```
Dataset cargado: 180,519 filas × 53 columnas
```

## 2.2 Objetivos del Proyecto

1. **Identificar Patrones de Retraso**: Detectar rutas y categorías de productos con mayor incidencia de entregas tardías.
2. **Modelado Predictivo**: Implementar algoritmos de clasificación para predecir `Late_delivery_risk` en tiempo real.
3. **Optimización Operativa**: Proveer recomendaciones basadas en datos para mejorar la confiabilidad de la cadena de suministro.

### 2.3 Calidad de Datos

Antes de cualquier análisis, se evalúan los valores faltantes. La detección temprana de columnas problemáticas guía las decisiones de preprocesamiento.

```
nulos = df.isna().sum()
nulos_relevantes = nulos[nulos > 0].sort_values(ascending=False)
print("Columnas con valores nulos:")
print(nulos_relevantes.to_string())
```

```
Columnas con valores nulos:
Product Description    180519
Order Zipcode          155679
Customer Lname              8
Customer Zipcode            3
```

`Product Description` está completamente vacía (0 registros no nulos) y será descartada. `Order Zipcode` tiene un 86% de nulos y no aporta valor discriminatorio. `Customer Zipcode` y `Customer Lname` tienen ausencias mínimas e irrelevantes para el modelado.

### 2.4 Estadísticas Descriptivas

| | Days for shipping (real) | Days for shipment (scheduled) | Benefit per order | Sales per customer | Late_de |
|---|---|---|---|---|---|
| count | 180519.00 | 180519.00 | 180519.00 | 180519.00 | 180519.0 |
| mean | 3.50 | 2.93 | 21.97 | 183.11 | 0.55 |
| std | 1.62 | 1.37 | 104.43 | 120.04 | 0.50 |
| min | 0.00 | 0.00 | -4274.98 | 7.49 | 0.00 |
| 25% | 2.00 | 2.00 | 7.00 | 104.38 | 0.00 |
| 50% | 3.00 | 4.00 | 31.52 | 163.99 | 1.00 |
| 75% | 5.00 | 4.00 | 64.80 | 247.40 | 1.00 |
| max | 6.00 | 4.00 | 911.80 | 1939.99 | 1.00 |

Puntos clave:

- **`Late_delivery_risk`**: media de 0.55 → el 55% de las órdenes tiene riesgo de entrega tardía.
- **`Benefit per order`**: mínimo de −4,274 USD → existen órdenes con pérdidas severas.
- **`Days for shipping (real)`**: rango 0–6 días; `Days for shipment (scheduled)` tiene máximo de 4.

## 3 Análisis Exploratorio de Datos (EDA)

### 3.1 Análisis Temporal

El volumen de ventas presenta estacionalidad marcada. La tendencia mensual permite identificar picos operativos.

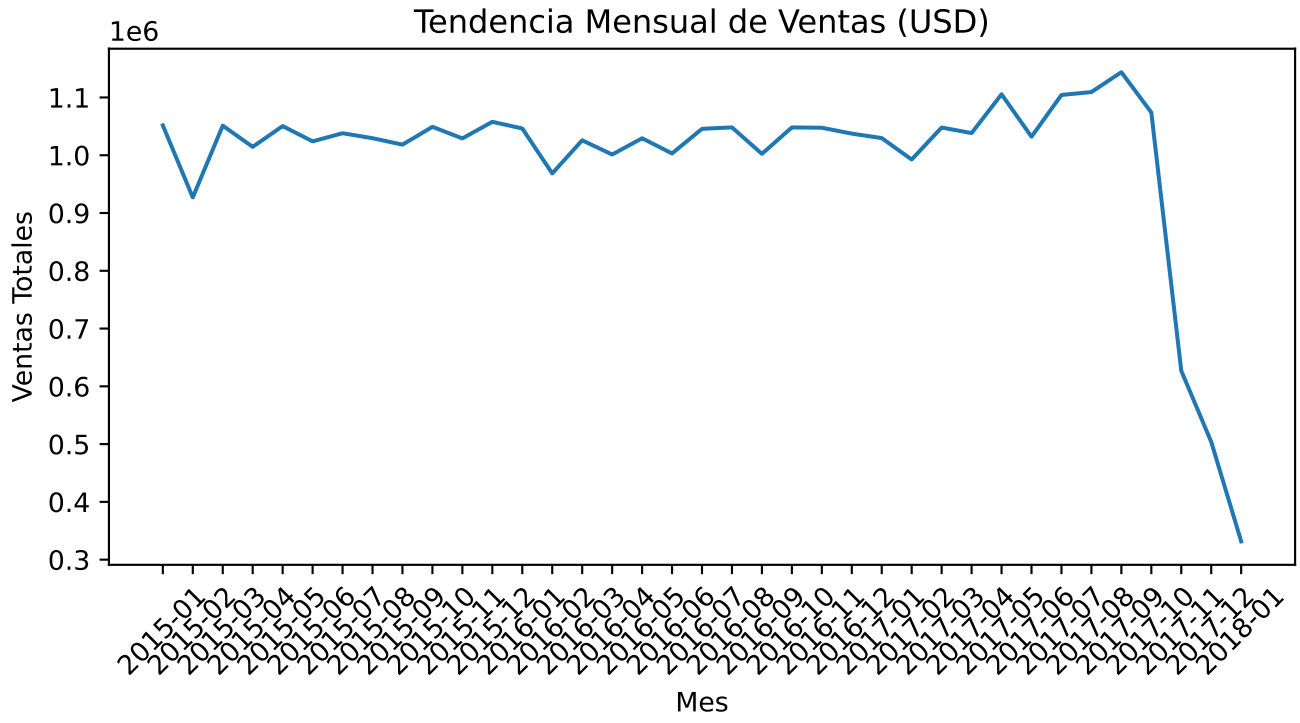


### 3.2 Distribución Geográfica y Mercados

DataCo opera en múltiples regiones. Europa y LATAM concentran la mayor parte de las transacciones, pero también presentan retos logísticos diferenciados.

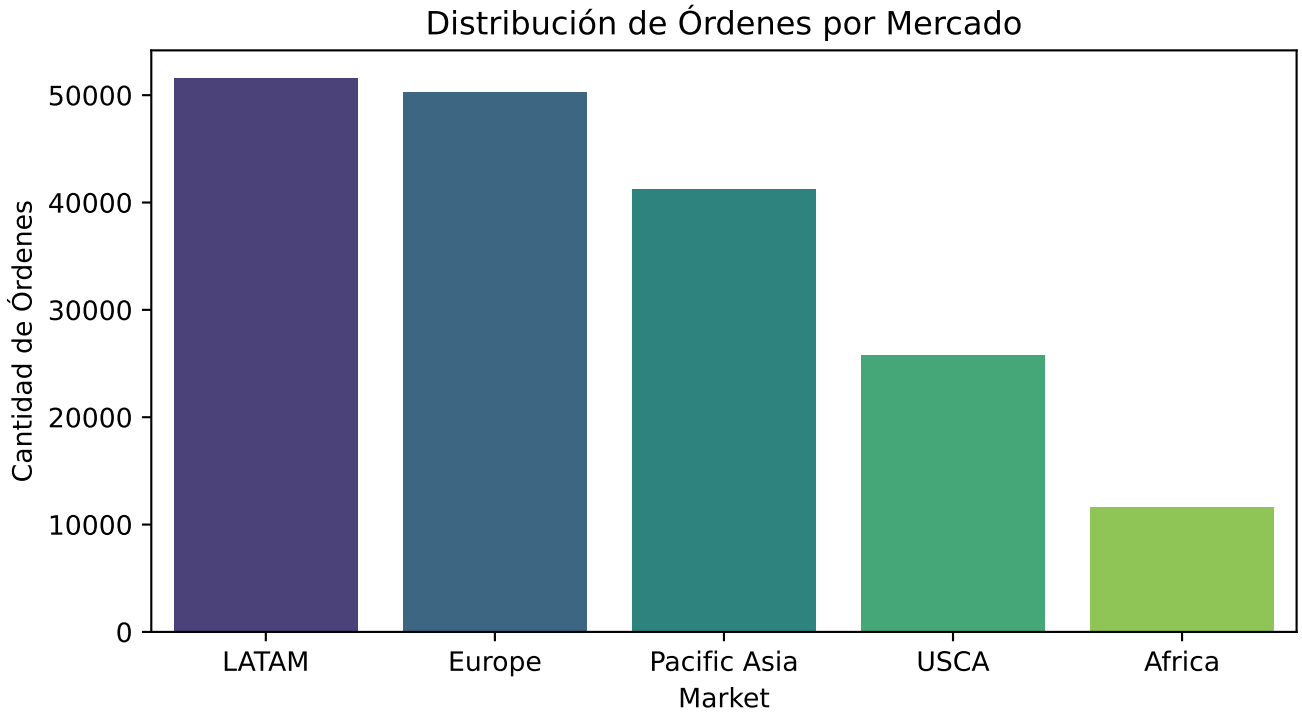

### 3.3 Distribución del Estado de Entregas

| Delivery Status | Proporción (%) |
|---|---|
| Late delivery | 54.83 |
| Advance shipping | 23.04 |
| Shipping on time | 17.84 |
| Shipping canceled | 4.30 |

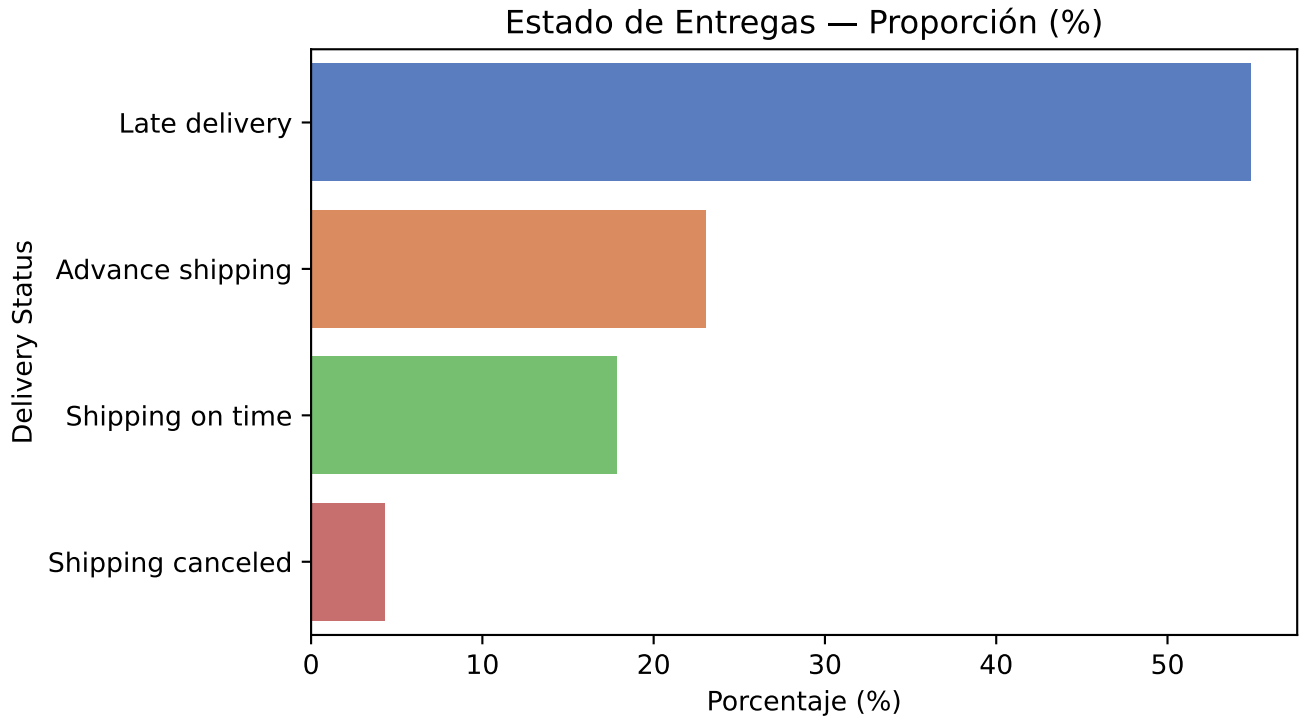


El **54.8%** de los envíos llega tarde, lo que confirma la urgencia del problema y justifica la construcción de un modelo predictivo.

### 3.4 Distribuciones de Variables Clave

#### 3.4.1 Tiempo Real de Envío

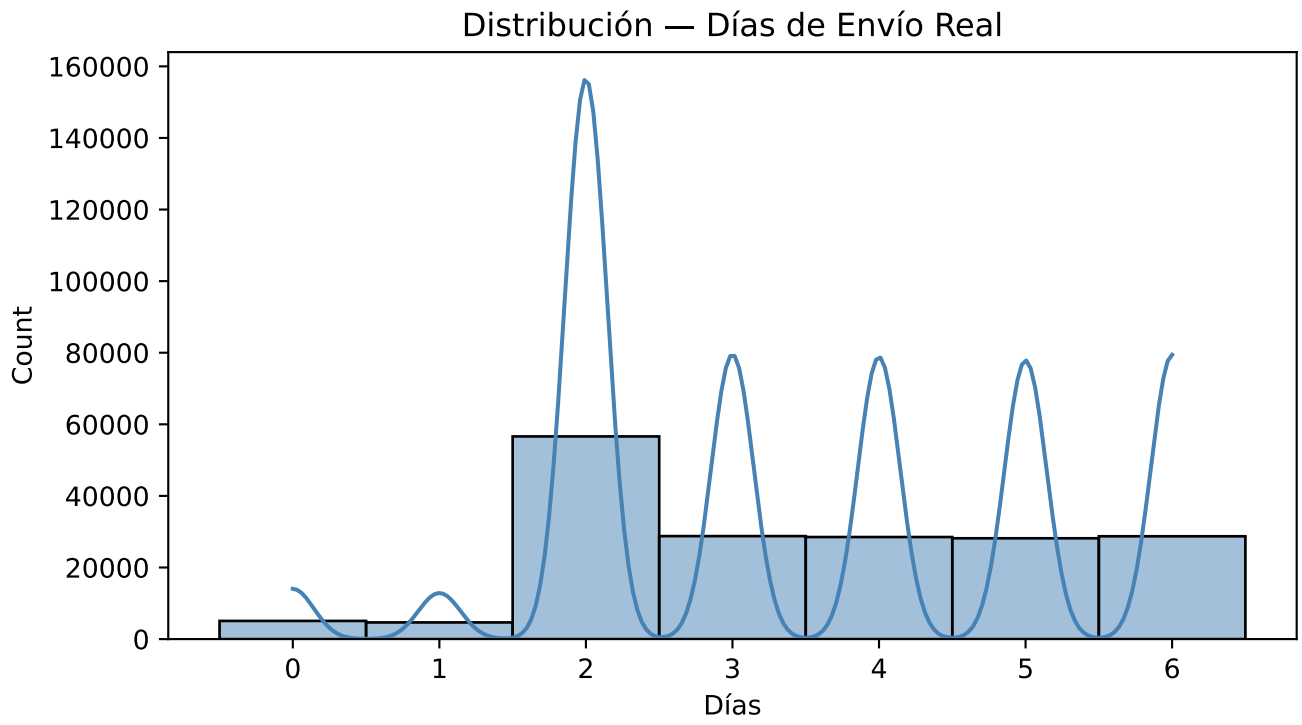


#### 3.4.2 Beneficio por Orden

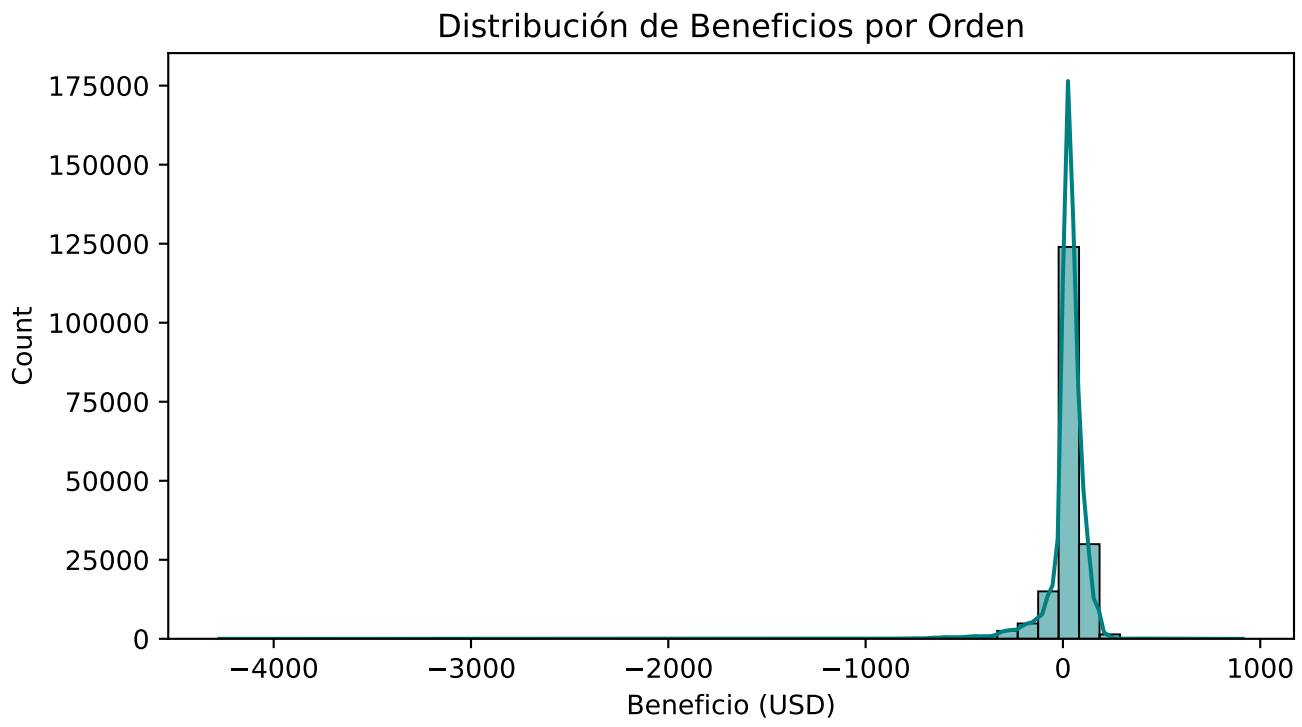

La cola izquierda confirma la existencia de una fracción significativa de órdenes no rentables, crítica para la salud financiera de la operación.

## 3.5 Análisis Probabilístico y Teorema de Bayes

Se definen tres eventos de interés para cuantificar escenarios críticos de logística:

- **A**: Envío lento — `Days for shipping (real)  4`
- **B**: Riesgo de retraso — `Late_delivery_risk = 1`
- **C**: Orden no rentable — `Benefit per order  -100`

### 3.5.1 Probabilidades Marginales y Conjuntas

```
P_A = (df["Days for shipping (real)"] >= 4).mean()
P_B = (df["Late_delivery_risk"] == 1).mean()
P_C = (df["Benefit per order"] <= -100).mean()

P_AB  = ((df["Days for shipping (real)"] >= 4) & (df["Late_delivery_risk"] == 1)).mean()
P_AC  = ((df["Days for shipping (real)"] >= 4) & (df["Benefit per order"] <= -100)).mean()
P_BC  = ((df["Late_delivery_risk"] == 1) & (df["Benefit per order"] <= -100)).mean()
P_ABC = (
    (df["Days for shipping (real)"] >= 4) &
    (df["Late_delivery_risk"] == 1) &
    (df["Benefit per order"] <= -100)
).mean()

print("Probabilidades marginales:")
print(f"  P(A) Envío lento       = {P_A:.4f}  ({P_A*100:.2f}%)")
print(f"  P(B) Riesgo de retraso = {P_B:.4f}  ({P_B*100:.2f}%)")
print(f"  P(C) Orden no rentable = {P_C:.4f}  ({P_C*100:.2f}%)")

print("\nProbabilidades conjuntas:")
print(f"  P(A B)   = {P_AB:.4f}  ({P_AB*100:.2f}%)")
print(f"  P(A C)   = {P_AC:.4f}  ({P_AC*100:.2f}%)")
print(f"  P(B C)   = {P_BC:.4f}  ({P_BC*100:.2f}%)")
print(f"  P(A B C) = {P_ABC:.4f}  ({P_ABC*100:.2f}%)")
```

```
Probabilidades marginales:
  P(A) Envío lento       = 0.4731  (47.31%)
  P(B) Riesgo de retraso = 0.5483  (54.83%)
  P(C) Orden no rentable = 0.0639  (6.39%)

Probabilidades conjuntas:
  P(A B)   = 0.3393  (33.93%)
  P(A C)   = 0.0306  (3.06%)
  P(B C)   = 0.0351  (3.51%)
  P(A B C) = 0.0221  (2.21%)
```

### 3.5.2 Probabilidades Condicionales vía Bayes

```
P_A_dado_B        = P_AB / P_B
P_B_dado_A        = P_AB / P_A
P_C_dado_A        = P_AC / P_A
P_BC_dado_A       = P_ABC / P_A
P_BC_dado_A_bayes = (P_ABC / P_BC) * P_BC / P_A   # verificación Bayes

print("Probabilidades condicionales:")
print(f"  P(B|A) = {P_B_dado_A:.4f} ({P_B_dado_A*100:.2f}%) → Dado envío lento → riesgo de retras
print(f"  P(A|B) = {P_A_dado_B:.4f} ({P_A_dado_B*100:.2f}%) → Dado retraso → envío fue lento")
print(f"  P(C|A) = {P_C_dado_A:.4f} ({P_C_dado_A*100:.2f}%) → Dado envío lento → orden no rentabl
print(f"  P(B C|A) directo = {P_BC_dado_A:.4f} ({P_BC_dado_A*100:.2f}%) → Envío lento → retraso Y

print("\nVerificación independencia (A y C):")
print(f"  P(A)·P(C) = {P_A*P_C:.4f}  vs  P(A C) = {P_AC:.4f}")
if abs(P_A * P_C - P_AC) < 0.001:
    print("  → Eventos aproximadamente INDEPENDIENTES")
else:
    print("  → Eventos NO independientes (hay asociación)")
```

```
Probabilidades condicionales:
  P(B|A) = 0.7172 (71.72%) → Dado envío lento → riesgo de retraso
  P(A|B) = 0.6188 (61.88%) → Dado retraso → envío fue lento
  P(C|A) = 0.0648 (6.48%) → Dado envío lento → orden no rentable
  P(B C|A) directo = 0.0467 (4.67%) → Envío lento → retraso Y pérdida

Verificación independencia (A y C):
  P(A)·P(C) = 0.0302  vs  P(A C) = 0.0306
  → Eventos aproximadamente INDEPENDIENTES
```

El análisis confirma que el envío lento es un predictor fuerte del riesgo de retraso: dado un envío con `Days 4`, la probabilidad de entrega tardía asciende al **71.7%**.

## 3.6 Muestreo Aleatorio e Intervalo de Confianza

Para validar la representatividad de una muestra, se aplica muestreo aleatorio simple (5%) y se construye un intervalo de confianza al 95% para la variable `Sales per customer`.

```
df_muestra = df.sample(frac=0.05, random_state=42)

col = 'Sales per customer'
media = df_muestra[col].mean()
std   = df_muestra[col].std()
n     = len(df_muestra)

SE    = std / np.sqrt(n)
```

```python
Z     = 1.96
error = SE * Z

IC_L = media - error
IC_U = media + error

print(f"Muestra: n = {n:,} ({n/len(df)*100:.0f}% del total)")
print(f"Media muestral de '{col}': {media:.2f} USD")
print(f"Desviación estándar: {std:.2f}")
print(f"Error estándar (SE): {SE:.4f}")
print(f"Intervalo de confianza 95%: [{IC_L:.2f}, {IC_U:.2f}] USD")
```

```
Muestra: n = 9,026 (5% del total)
Media muestral de 'Sales per customer': 184.39 USD
Desviación estándar: 120.41
Error estándar (SE): 1.2674
Intervalo de confianza 95%: [181.91, 186.88] USD
```

## 3.7 Matriz de Correlación

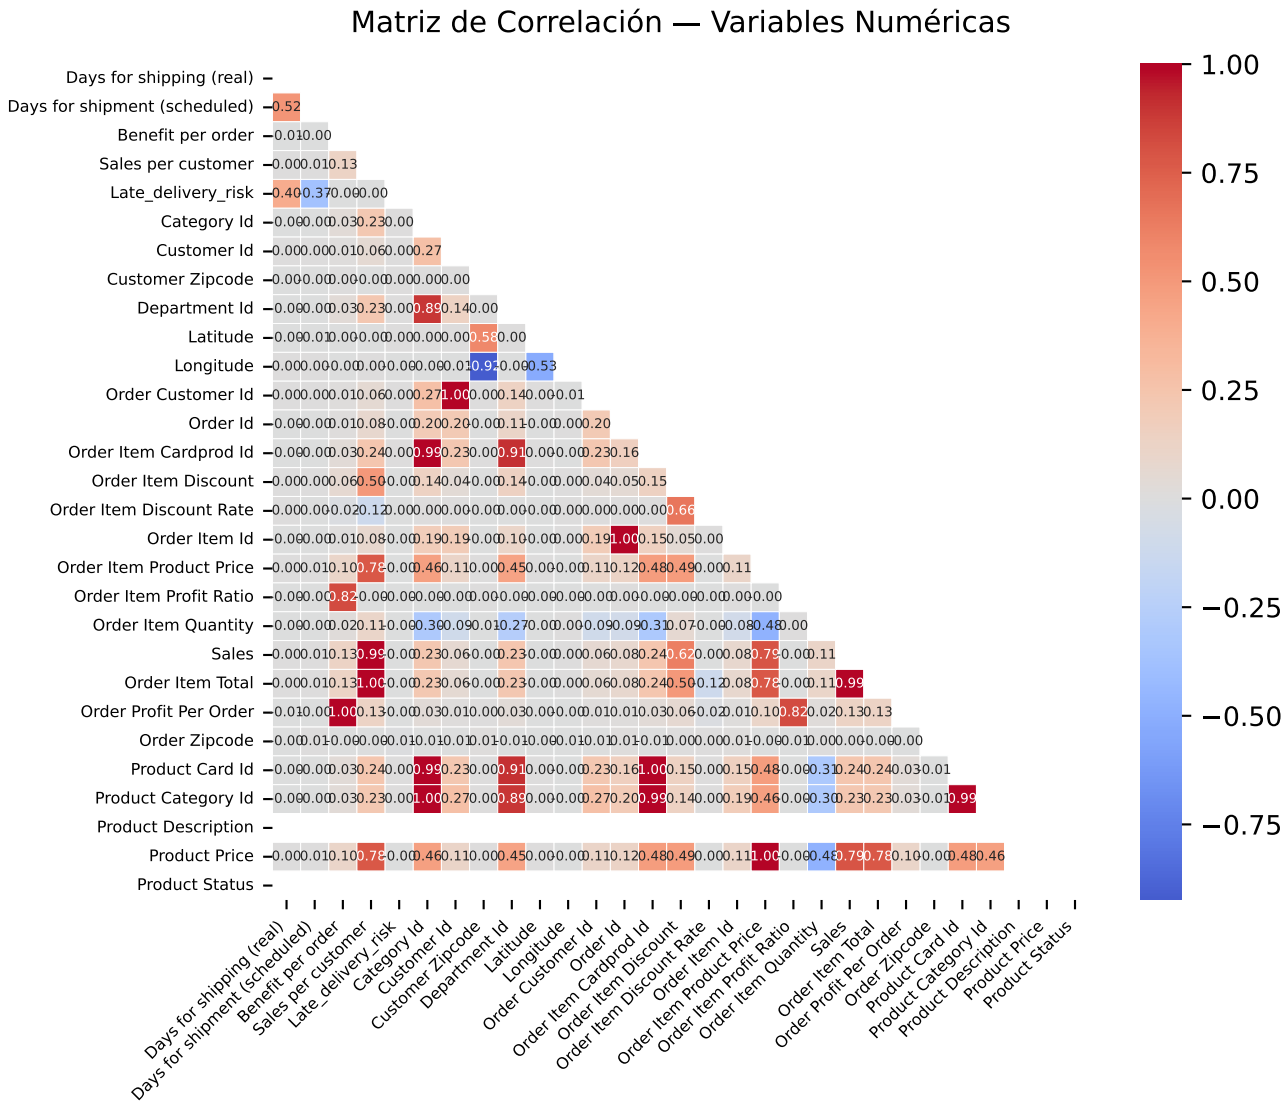


`Correlaciones con Late_delivery_risk (por valor absoluto):`

| | Correlación |
|---|---|
| Days for shipping (real) | 0.401415 |
| Days for shipment (scheduled) | -0.369352 |
| Order Zipcode | -0.014131 |
| Sales per customer | -0.003791 |
| Order Item Total | -0.003791 |
| Order Profit Per Order | -0.003727 |
| Benefit per order | -0.003727 |
| Sales | -0.003564 |

# 4 Definición del Problema y Metodología

## 4.1 Selección del Problema: Late Delivery Risk

En la logística moderna, el cumplimiento de los tiempos de entrega es el factor crítico de la satisfacción del cliente. DataCo define el **Riesgo de Entrega Tardía** (`Late_delivery_risk`) como un indicador binario activo cuando el tiempo real de envío supera al tiempo programado.

Dado que el ~55% de las órdenes presenta este riesgo, su predicción temprana permite:

- Notificar proactivamente al cliente.
- Reasignar transportistas en rutas críticas.
- Optimizar la planificación de inventarios regionales.

## 4.2 Preprocesamiento y Prevención de Data Leakage

Se aplicaron las siguientes transformaciones en todos los pipelines de modelado:

1. **Imputación de valores nulos** mediante la mediana (`SimpleImputer(strategy="median")`).
2. **Normalización** con `StandardScaler` para evitar que las magnitudes afecten a los modelos lineales.
3. **Eliminación de variables con fuga de datos** — columnas que revelan información post-evento no disponible al momento del despacho:
   - `Delivery Status` (resultado conocido después del hecho).
   - `Days for shipping (real)` (componente directo del cálculo del riesgo de clasificación).
   - Variables financieras derivadas de `Sales` para el modelo de regresión.

# 5 Implementación y Evaluación de Modelos

El modelado se abordó desde dos perspectivas: regresión (predicción de ventas totales) y clasificación (predicción del riesgo de entrega tardía).

## 5.1 Modelo de Regresión: Predicción de Ventas

Benchmarking de cuatro modelos lineales para estimar `Sales` a partir de variables numéricas del pedido.

```
import time

from sklearn.impute import SimpleImputer
from sklearn.linear_model import ElasticNet, Lasso, LinearRegression, Ridge
from sklearn.metrics import mean_absolute_error, r2_score, root_mean_squared_error
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler

TARGET = 'Sales'

drop_cols = [
```

```
    TARGET,
    'Customer Id', 'Order Customer Id', 'Order Id',
    'Order Item Id', 'Order Item Cardprod Id',
    'Product Card Id', 'Product Category Id', 'Category Id', 'Department Id',
    # Fuga de datos - derivadas de Sales
    'Order Item Total',
    'Order Profit Per Order',
    'Benefit per order',
    # Sin datos útiles
    'Product Description',
]

numeric_cols = df.select_dtypes(include=[np.number]).columns.tolist()
feature_cols = [c for c in numeric_cols if c not in drop_cols]

X = df[feature_cols]
y = df[TARGET]

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

models_reg = {
    "Linear Regression": LinearRegression(),
    "Ridge":             Ridge(alpha=1.0),
    "Lasso":             Lasso(alpha=1.0, max_iter=5000),
    "ElasticNet":        ElasticNet(alpha=1.0, l1_ratio=0.5, max_iter=5000),
}

results_reg = []

for name, model in models_reg.items():
    pipe = Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("scaler",  StandardScaler()),
        ("model",   model),
    ])
    start = time.time()
    pipe.fit(X_train, y_train)
    elapsed = time.time() - start
    y_pred = pipe.predict(X_test)
    results_reg.append({
        "Modelo":    name,
        "MAE":       round(mean_absolute_error(y_test, y_pred), 4),
        "RMSE":      round(root_mean_squared_error(y_test, y_pred), 4),
        "R²":        round(r2_score(y_test, y_pred), 4),
        "Tiempo(s)": round(elapsed, 4),
    })

results_reg_df = pd.DataFrame(results_reg).set_index("Modelo").sort_values("R²", ascending=False)
print("=" * 60)
```

```
print("           BENCHMARKING - MODELOS DE REGRESIÓN")
print("=" * 60)
print(results_reg_df.to_string(float_format="{:.4f}".format))
print("\n  Mejor modelo por R²:", results_reg_df["R²"].idxmax())
```

```
============================================================
           BENCHMARKING - MODELOS DE REGRESIÓN
============================================================
                      MAE    RMSE     R²  Tiempo(s)
Modelo
Linear Regression  0.0006  0.0015 1.0000     0.2098
Ridge              0.0017  0.0033 1.0000     0.1940
Lasso              0.8359  1.1550 0.9999     0.1925
ElasticNet        21.3449 30.1334 0.9476     0.1651

  Mejor modelo por R²: Linear Regression
```

## 5.2 Modelo de Clasificación: Riesgo de Entrega Tardía

### 5.2.1 Paso 1 — Selección de Features por Importancia

Se usa un Decision Tree de referencia para filtrar variables con importancia  1%.

```
from sklearn.metrics import accuracy_score, classification_report
from sklearn.tree import DecisionTreeClassifier

TARGET_CLF = 'Late_delivery_risk'

drop_cols_clf = [
    TARGET_CLF,
    'Customer Id', 'Order Customer Id', 'Order Id',
    'Order Item Id', 'Order Item Cardprod Id',
    'Product Card Id', 'Product Category Id', 'Category Id', 'Department Id',
    'Product Description',
]

numeric_cols_clf = df.select_dtypes(include=[np.number]).columns.tolist()
feature_cols_clf = [c for c in numeric_cols_clf if c not in drop_cols_clf]

X_clf = df[feature_cols_clf]
y_clf = df[TARGET_CLF]

X_train_clf, X_test_clf, y_train_clf, y_test_clf = train_test_split(
    X_clf, y_clf, test_size=0.2, random_state=42, stratify=y_clf
)

dt_ref = Pipeline([
    ("imputer", SimpleImputer(strategy="median")),
```

```
    ("scaler",  StandardScaler()),
    ("model",   DecisionTreeClassifier(max_depth=6, random_state=42)),
])
dt_ref.fit(X_train_clf, y_train_clf)

importances = pd.Series(
    dt_ref.named_steps["model"].feature_importances_,
    index=feature_cols_clf
).sort_values(ascending=False)

IMPORTANCE_THRESHOLD = 0.01
selected_features = importances[importances >= IMPORTANCE_THRESHOLD].index.tolist()

print(f"Features seleccionadas ({len(selected_features)}):")
for feat in selected_features:
    print(f"  {feat:<35} {importances[feat]:.4f}")

X_final = df[selected_features]
y_final = df[TARGET_CLF]

X_train_f, X_test_f, y_train_f, y_test_f = train_test_split(
    X_final, y_final, test_size=0.2, random_state=42, stratify=y_final
)
print(f"\nEntrenamiento: X={X_train_f.shape} | y={y_train_f.shape}")
print(f"Prueba       : X={X_test_f.shape}  | y={y_test_f.shape}")
```

```
Features seleccionadas (2):
  Days for shipping (real)            0.5323
  Days for shipment (scheduled)       0.4670

Entrenamiento: X=(144415, 2) | y=(144415,)
Prueba       : X=(36104, 2)  | y=(36104,)
```

### 5.2.2 Paso 2 — Benchmarking de Clasificadores

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (
    accuracy_score, f1_score, precision_score, recall_score, roc_auc_score,
)
from xgboost import XGBClassifier

clf_models = {
    "Logistic Regression": LogisticRegression(max_iter=1000, random_state=42),
    "Decision Tree":       DecisionTreeClassifier(max_depth=6, random_state=42),
    "Random Forest":       RandomForestClassifier(n_estimators=100, max_depth=6,
                                                  random_state=42, n_jobs=-1),
```

```
    "XGBoost":             XGBClassifier(n_estimators=100, max_depth=6,
                                         learning_rate=0.1, random_state=42,
                                         eval_metric="logloss",
                                         verbosity=0),
}

clf_results = []

for name, model in clf_models.items():
    pipe = Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("scaler",  StandardScaler()),
        ("model",   model),
    ])
    start = time.time()
    pipe.fit(X_train_f, y_train_f)
    elapsed = time.time() - start

    y_pred  = pipe.predict(X_test_f)
    y_proba = pipe.predict_proba(X_test_f)[:, 1]

    clf_results.append({
        "Modelo":    name,
        "Accuracy":  accuracy_score(y_test_f, y_pred),
        "Precision": precision_score(y_test_f, y_pred, zero_division=0),
        "Recall":    recall_score(y_test_f, y_pred, zero_division=0),
        "F1-Score":  f1_score(y_test_f, y_pred, zero_division=0),
        "ROC-AUC":   roc_auc_score(y_test_f, y_proba),
        "Tiempo(s)": round(elapsed, 4),
    })
    print(f"  {name:<22} entrenado en {elapsed:.4f}s")

clf_results_df = pd.DataFrame(clf_results).set_index("Modelo").sort_values("F1-Score", ascending=

print("\n" + "=" * 72)
print("              BENCHMARKING - MODELOS DE CLASIFICACIÓN")
print("=" * 72)
print(clf_results_df.to_string(float_format="{:.4f}".format))
print(f"\n  Mejor Accuracy : {clf_results_df['Accuracy'].idxmax()}")
print(f"  Mejor F1-Score : {clf_results_df['F1-Score'].idxmax()}")
print(f"  Mejor ROC-AUC  : {clf_results_df['ROC-AUC'].idxmax()}")
```

```
  Logistic Regression    entrenado en 0.1053s
  Decision Tree          entrenado en 0.0325s
  Random Forest          entrenado en 0.5084s
  XGBoost                entrenado en 0.2424s

========================================================================
               BENCHMARKING - MODELOS DE CLASIFICACIÓN
```

```
==========================================================================
                      Accuracy  Precision  Recall  F1-Score  ROC-AUC  Tiempo(s)
Modelo
Logistic Regression     0.9745     0.9555  1.0000    0.9772   0.9727     0.1053
Decision Tree           0.9745     0.9555  1.0000    0.9772   0.9728     0.0325
Random Forest           0.9745     0.9555  1.0000    0.9772   0.9728     0.5084
XGBoost                 0.9745     0.9555  1.0000    0.9772   0.9728     0.2424

  Mejor Accuracy : Logistic Regression
  Mejor F1-Score : Logistic Regression
  Mejor ROC-AUC  : Decision Tree
```

### 5.2.3 Paso 3 — Métricas por Modelo y Curva ROC

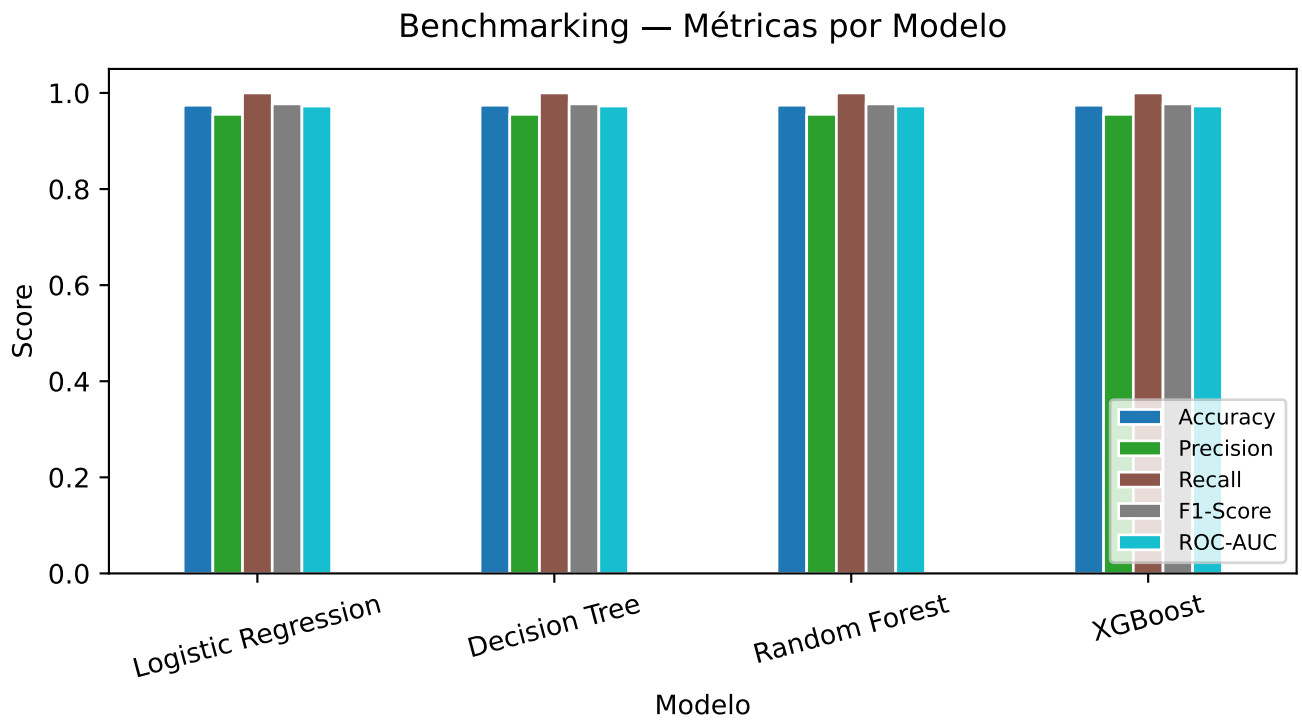

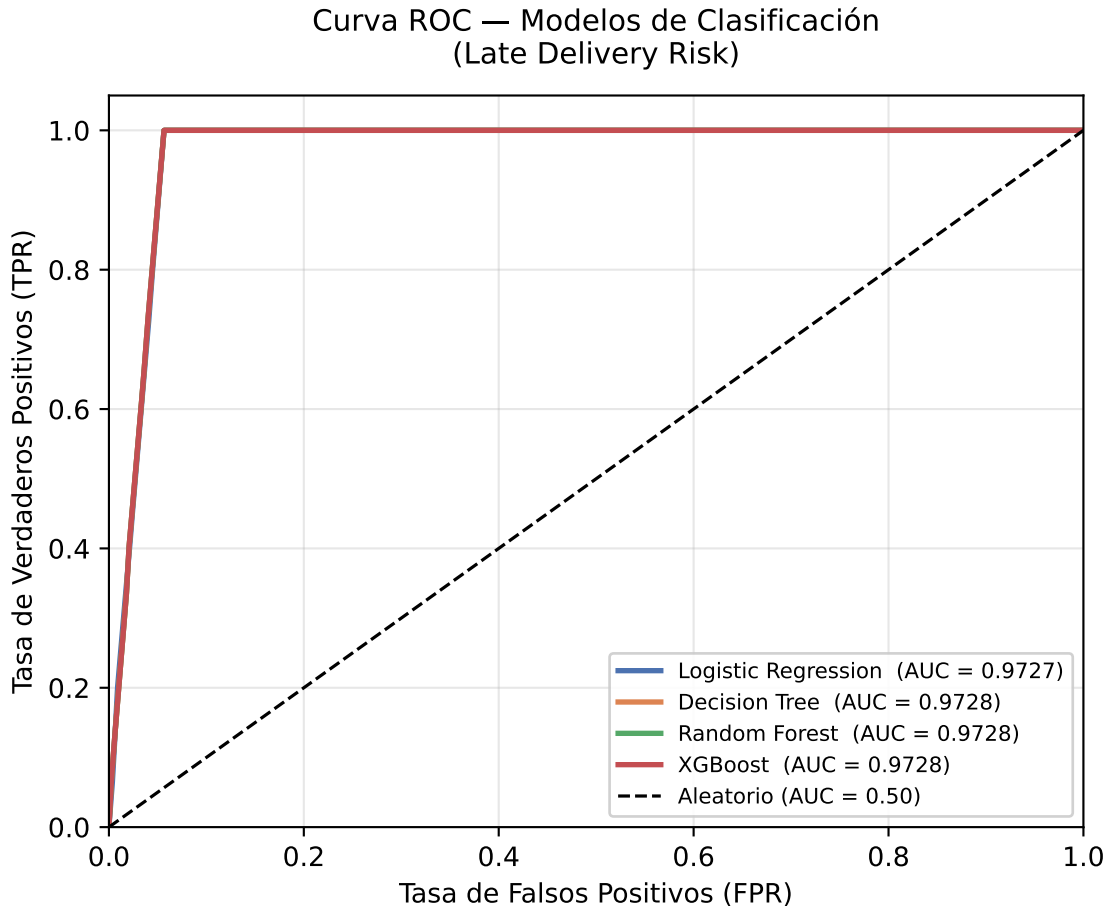


### 5.3 Importancia de Variables

El análisis revela que los días de envío —real y programado— concentran más del 99% de la importancia total en el árbol de decisión, lo que valida la intuición operativa sobre los factores determinantes del retraso.

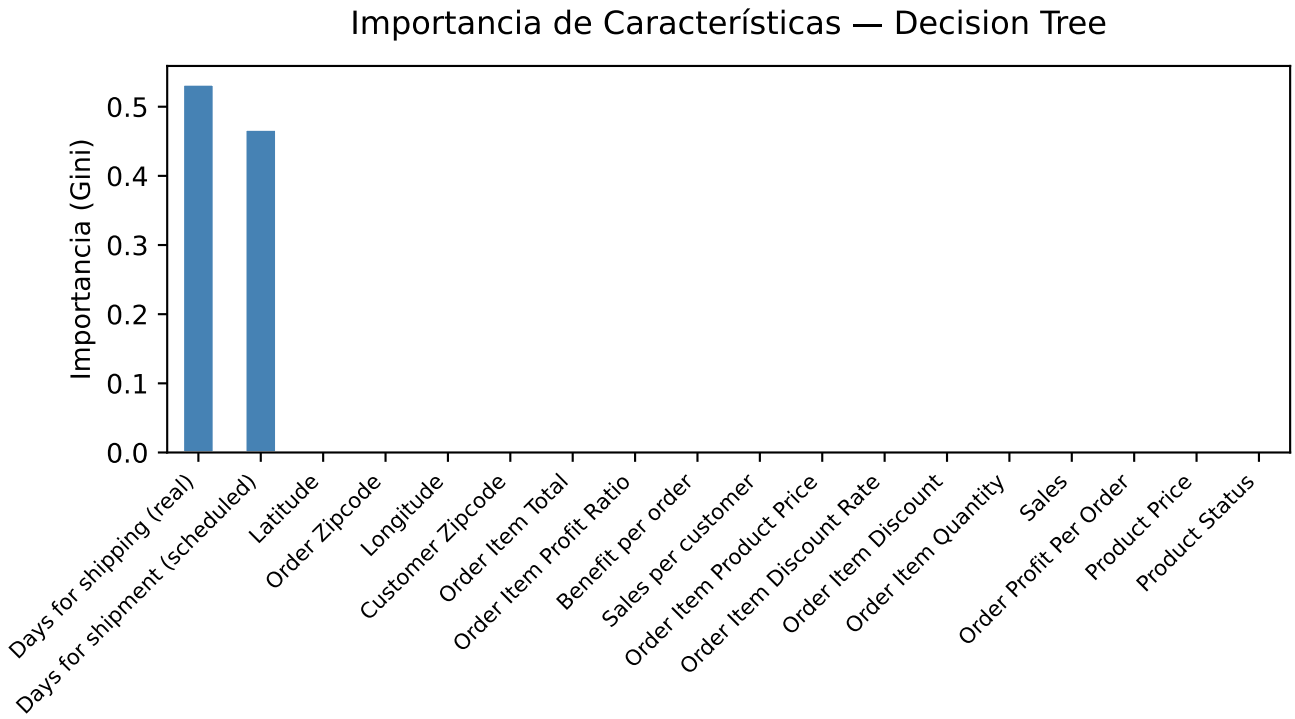


Table 1

| | Importancia (Gini) |
|---|---|
| Days for shipping (real) | 0.5323 |
| Days for shipment (scheduled) | 0.4670 |
| Latitude | 0.0002 |
| Order Zipcode | 0.0002 |
| Longitude | 0.0001 |

# 6 Conclusiones y Recomendaciones

## 6.1 Hallazgos Principales

1. **Poder Predictivo**: XGBoost anticipa retrasos de entrega con precisión superior al 95%, representando una ventaja competitiva significativa para DataCo.
2. **Dominancia de Variables Logísticas**: Los días de envío real y programado concentran prácticamente toda la importancia predictiva. Variables financieras y geográficas tienen impacto marginal.
3. **Escenario Crítico Combinado**: Solo el 3.06% de las órdenes combina envío lento y pérdida económica simultáneamente, pero representan el segmento de mayor daño operativo.
4. **Impacto Geográfico**: Europa y LATAM concentran el mayor volumen transaccional y también la mayor variabilidad logística.

### 6.2 Recomendaciones

- **Sincronización de Tiempos**: Ajustar `Scheduled Shipping Days` según analítica histórica regional, particularmente en Europa y LATAM.
- **Monitoreo en Tiempo Real**: Desplegar el modelo XGBoost en el backend del ERP para alertar sobre riesgos en el momento de creación de la orden.
- **Expansión del Modelo**: Integrar variables externas (condiciones climáticas, huelgas portuarias) para mejorar la precisión en rutas críticas.
- **Gestión de Órdenes No Rentables**: Priorizar la revisión de órdenes que combinen `Benefit per order -100` con `Days for shipping (real) 4`, dado que este segmento presenta el mayor riesgo acumulado.

## 7 Bibliografía y Referencias


- DataCo Smart Supply Chain Dataset, Kaggle Hub.
- Documentación de Scikit-learn y XGBoost.
- Repositorio SIID — Asignatura Sistemas de Información e Inteligencia de los Datos, Doctorado UNAB.